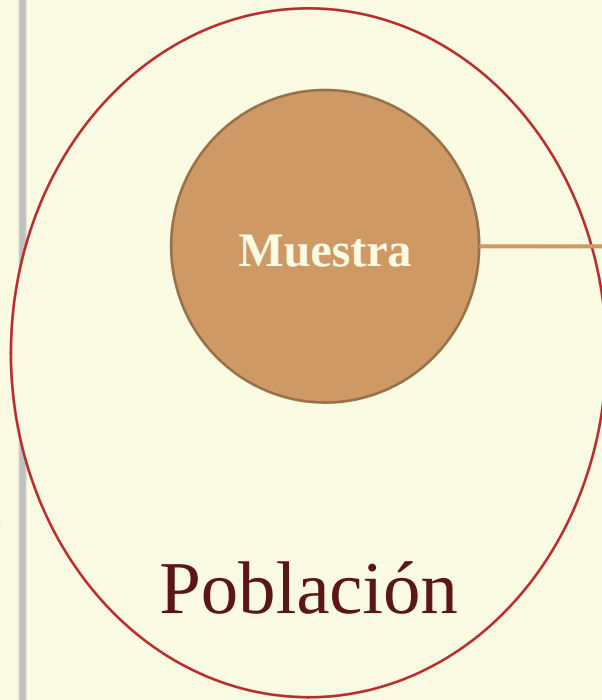


# Estimación



Esperamos que sea *representativa*. Para ello, se toma al azar de entre toda la población.

$$\{ \mathbf{x}_i \}_{i=1}^n$$

Estimamos (“aproximamos”) un valor de la población total basados sólo en la muestra.

# Estimación




Esperamos que sea *representativa*. Para ello, se toma al azar de entre toda la población.

$$\{X_i\}_{i=1}^n$$

**Estadístico:** una función de la muestra

**Estimación:** una aproximación al valor de interés

# Estimación



**Estimador:** variable aleatoria correspondiente a las estimaciones de basados en una muestra al azar

# Dos medidas de performance

---

**Sesgo**

**Error cuadrático medio**

**Error cuadrático medio**

# Propiedades deseables

---

**Consistente (una versión)**

**Estimador insesgado**

# Ejemplos de estimadores

## Media

---

Si

**Es insesgado y consistente**

# Ejemplos de estimadores

## Proporción

---

Si  $p$  con probabilidad  $p$  y con probabilidad  $1-p$

**Es insesgado y consistente**

# Ejemplos de estimadores

## Varianza

---

Si

**Es insesgado y consistente**

**Su distribución depende de la distribución de**



# ¿De dónde salen los estimadores?

---

Existen numerosas técnicas.

Vamos a presentar la idea de algunas.

- Máxima verosimilitud
- Máximo a posteriori
- Método de los momentos
- Cuadrados mínimos

# Máxima verosimilitud

La distribución conjunta de las variables viene dada por

$$f(x_1, \dots, x_n; \theta)$$

es el parámetro que se quiere estimar. Lo que se hace es buscar el valor del parámetro que maximiza la probabilidad (verosimilitud) para los valores dados de la muestra .

# Máxima verosimilitud

Ejemplo: i.i.d. y se desea estimar :

$$f(x_1, \dots, x_n; \mu) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

$$L(\mu) = \ln(f(x_1, \dots, x_n; \mu)) = n \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}$$

$$\frac{dL(\mu)}{d\mu} = \sum_{i=1}^n \frac{(x_i - \mu)}{\sigma^2} = \frac{1}{\sigma^2} \left( \sum_{i=1}^n x_i - n\mu \right) = 0 \Rightarrow \hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i$$

# Máximo a posteriori

Permite incorporar información previa sobre el parámetro a estimar.

La visión Bayesiana: es una variable aleatoria.

La distribución conjunta de las variables dado un valor del parámetro viene dada por

$$f(x_1, \dots, x_n \vee \theta)$$

La información sobre el parámetro es especificada por una *prior* (distribución de probabilidades de )

$$g(\theta)$$

# Máximo a posteriori

Luego de ver las muestras, se puede calcular la distribución de actualizada (*a posteriori*)

$$g(\theta | x_1, \dots, x_n) = \frac{f(x_1, \dots, x_n | \theta) g(\theta)}{\int f(x_1, \dots, x_n | \theta) g(\theta) d\theta}$$

Como estimador, se elige el valor que maximiza esta distribución

$$\hat{\theta} = \underset{\theta}{\operatorname{argmax}} g(\theta | x_1, \dots, x_n)$$

# Máximo a posteriori

Ejemplo: i.i.d. y se desea estimar .

$$f(x_1, \dots, x_n | \mu) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

Pero se sabe que debe estar cerca de . Esto se escribe como .

$$g(\mu) = \frac{1}{\sqrt{2\pi\sigma_p^2}} e^{-\frac{(\mu - \mu_p)^2}{2\sigma_p^2}}$$

# Máximo a posteriori

$$g(\theta | x_1, \dots, x_n) \propto \frac{1}{\sqrt{2\pi\sigma_p^2}} e^{-\frac{(\mu - \mu_p)^2}{2\sigma_p^2}} \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

Luego de algunas cuentas...

$$\hat{\mu} = \frac{\sigma^2}{\sigma^2 + n\sigma_p^2} \mu_p + \frac{n\sigma_p^2}{\sigma^2 + n\sigma_p^2} \bar{x}$$

Si ,

Si ,

# Método de las potencias

Existe un estimador conocido para un momento de la variable aleatoria

$$\hat{\mu}_k = h(x_1, \dots, x_n)$$

Hay una dependencia conocida entre el momento y el parámetro

$$\mu_k = H(\theta)$$

Se resuelve la ecuación

$$H(\theta) = h(x_1, \dots, x_n)$$



# Método de las potencias

Ejemplo: i.i.d. y se desea estimar :

$$\mu = E[X_i] = \frac{1}{\lambda}$$

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\Rightarrow \hat{\lambda} = \frac{1}{\frac{1}{n} \sum_{i=1}^n x_i}$$