



APRENDIZAJE NO SUPERVISADO

Regla de Oja y Sanger

TABLA DE CONTENIDOS

01. INTRODUCCIÓN

02. MODELO DE
KOHONEN

03. MODELO DE
HOPFIELD

04. AUTOVALORES Y
AUTOVECTORES

05. COMPONENTES
PRINCIPALES

06. REGLA DE OJA Y
SANGER

06.1

COMPONENTES PRINCIPALES

Repaso

COMPONENTES PRINCIPALES



Repaso:

Componentes principales

Utilizadas para extraer características destacadas o importantes de un conjunto de datos bajando la dimensión.

COMPONENTES PRINCIPALES



Algunos modelos de redes neuronales permiten calcular las componentes principales en forma iterativa:

- **Ventaja:** reduce costo computacional (cantidad de registros muy grande, o muchas variables)
- **Desventaja:** Si el dataset tiene muchas variables, interpretarlo en una sola se puede perder información, al reducir tan drásticamente la dimensión.

06

REGLA DE OJA Y SANGER

PERCEPTRON LINEAL SIMPLE

Dados n datos de entrada, x_1, \dots, x_n , una red neuronal calcula la salida

$$O^\mu = \theta\left(\sum_{i=1}^n x_i^\mu w_i^\mu\right)$$

Actualizar los pesos,

$$\Delta w = \eta(\zeta^\mu - O^\mu)x^\mu$$

$$w(n+1) = w(n) + \Delta w$$

APRENDIZAJE HEBBIANO

Regla de Aprendizaje Hebbiano para **Aprendizaje No supervisado**

Dados m datos de entrada, x^1, \dots, x^m , una red neuronal calcula la salida

$$O^\mu = \theta\left(\sum_{i=1}^n x_i^\mu w_i^\mu\right)$$

No se conoce el valor de verdad, entonces:

$$\Delta w = \eta O^\mu x^\mu$$

CONVERGENCIA

Oja demostró que:

Si la red anterior converge, el vector de pesos resultante w^{final} sería un punto sobre la dirección de máxima variación de los datos (**la primer componente principal.**)

Pero...

El problema es que **no converge** porque el Δw va aumentando en cada paso y se hace tan grande que produce que el algoritmo sea inestable.

REGLA DE OJA

Dr. Erkki Oja, Helsinki University of Technology, Finland

$$\Delta w = \eta O^\mu x^\mu$$

$$w_j^{n+1} = \frac{w_j^n + \Delta w}{(\sum_{j=1}^N (w_j^n + \Delta w)^2)^{0.5}}$$

REGLA DE OJA

Utilizando el polinomio de Taylor

$$w_j^{n+1} = w_j^n + \eta \left(\frac{Ox^n x_j^n}{||w||} - \frac{w_j \sum_{j=1}^N (Ox^n x_j^n w_j)}{||w||^3} \right)$$

$$= w_j^n + \eta \left(\frac{Ox^n x_j^n}{||w||} - \frac{w_j^n O n^n \sum_{j=1}^N (x_j^n w_j^n)}{||w||^3} \right)$$

CONVERGENCIA

$|w|$ se mantiene acotado. Tiende a 1

Luego de varias iteraciones el método converge al **autovector** correspondiente al **mayor autovalor** de la matriz de correlaciones de los datos de entrada.

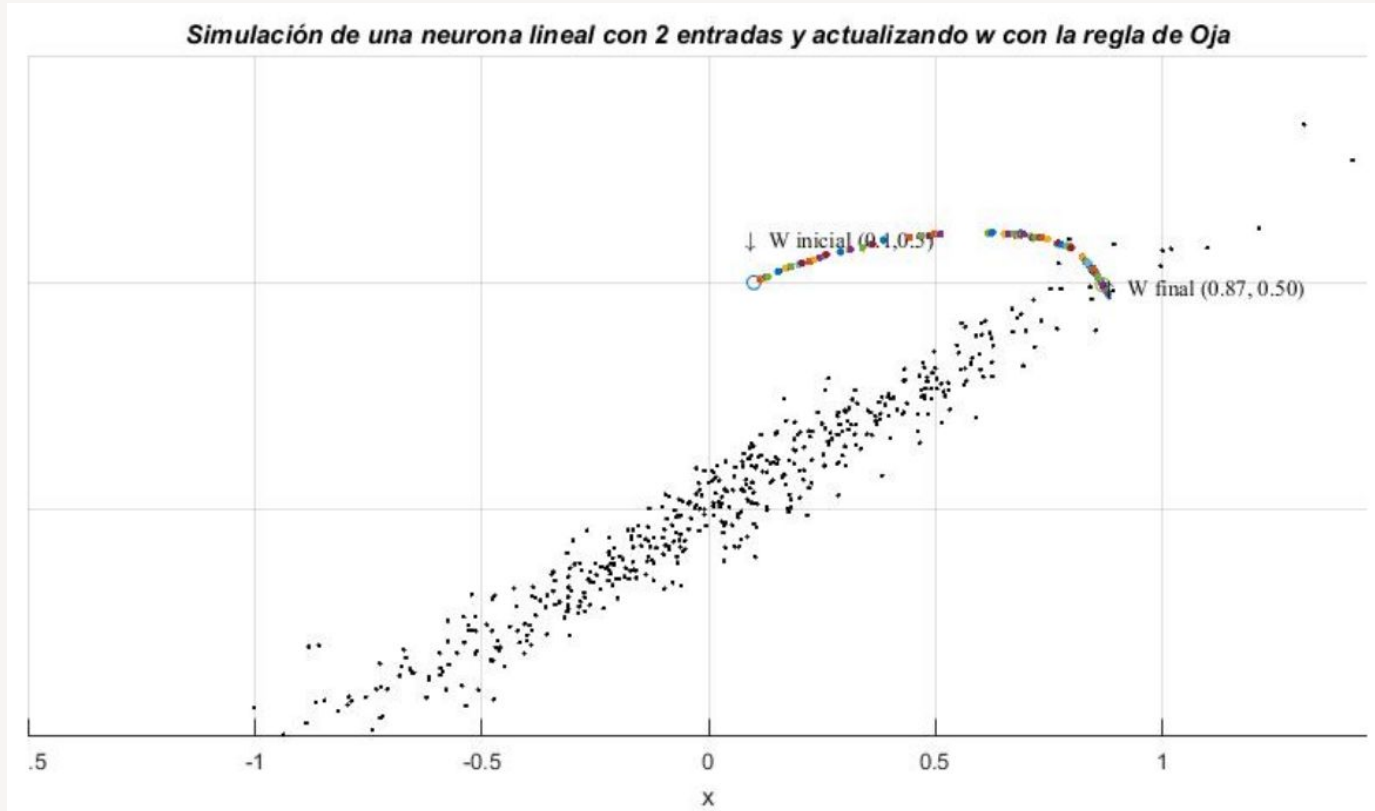
Con este vector **w final** se construye la primera componente principal.

$$y_1 = a_1x_1 + \dots + a_nx_n$$

Los a_i forman el primer autovector que sería el w^{final}

$$\Delta w = \eta(Ox_i^n - O^2w_i^n)$$

CONVERGENCIA



TASA DE APRENDIZAJE

Para asegurar la convergencia

$$\eta_0 = \frac{1}{1.2\lambda_1}$$

Como no conocemos el autovalor es mejor estandarizar todas las variables de entradas y comenzar con

$$\eta_0 \leq 0.5$$

IMPLEMENTACIÓN

Arquitectura

Es un perceptrón simple con una capa de salida

Actualización de Pesos

Según la Regla de Oja

Inicialización de Pesos

Distribución uniforme entre 0 y 1

Tasa de Aprendizaje

$\eta(0) = 0.5$ y disminuye
o $\eta = 10^{-3}$

ALGORITMO

input: X datos de dimensión N con media 0; η , w inicial con distribución uniforme entre 0 y 1

for epoch in #epochs

for i=1 to N

y = inner(x_i , w)

#calcular el output

w += $\eta * y * (x_i - y * w)$

#actualizar según regla de oja $\Delta w = \eta(Ox_i^n - O^2w_i^n)$

return(w)

REGLA DE SANGER

Extensión de la regla de Oja

- Converge a la matriz de autovectores de la matriz de covarianzas de los datos.
- Permite encontrar todas las componentes principales (k autovectores)