



APRENDIZAJE NO SUPERVISADO

Modelo de Hopfield

TABLA DE CONTENIDOS

01. INTRODUCCIÓN

02. MODELO DE KOHONEN

03. MODELO DE HOPFIELD

04. AUTOVALORES Y AUTOVECTORES

05. COMPONENTES PRINCIPALES

06. REGLA DE OJA Y SANGER

03.1

MODELO DE HOPFIELD

Arquitectura de Red

MEMORIAS ASOCIATIVAS

El almacenamiento y recuperación de información por **asociación** con otras informaciones

Consiste en almacenar un conjunto de p patrones tal que

- cuando se presenta un nuevo patrón P_{in} , la red responda con el patrón almacenado P_{out} que más se parece a P_{in}

P_{in} = Estímulo


P_{out} = Respuesta

MODELO DE HOPFIELD

Propuesto en 1982 por JJ. Hopfield


Red Recurrente

Existe retroalimentación entre las neuronas, están todas conectadas entre sí
(a diferencia de las redes feed-forward)



MODELO DE HOPFIELD

- Las neuronas no están conectadas con sí mismas
- Conjunto de input y output permitido $\{-1, 1\}$
(activo o inactivo)
- Todas las neuronas están en una sola capa de entrada y salida



En esta materia se verá el modelo discreto

OBJETIVO

¿Para qué sirve?

Asociar un patrón de consulta binario (con perturbaciones)
con alguno de los patrones almacenados

INPUT: patrón ruidoso
OUTPUT: el más similar

EJEMPLO

1	1
-1	-1

$$\mathcal{E}_1 = (1, 1, -1, -1)$$

-1	-1
1	1

$$\mathcal{E}_2 = (-1, -1, 1, 1)$$

¿Qué patrón se le asigna al siguiente vector de consulta? $\zeta = (1, -1, -1, -1)$

ESTADOS

Cada neurona tiene 2 estados

- $S_i = +1$ (activo)
- $S_i = -1$ (inactivo)

Para una red de N neuronas el estado queda representado por el vector de estados

$$S = [S_1, S_2, \dots, S_N]$$

PLANTEO DEL PROBLEMA

Dados los patrones almacenados ξ^μ , $\mu = 1, \dots, p$.

Presentamos un nuevo patrón ζ

Queremos encontrar el patrón almacenado más cercano a ζ (usando redes neuronales)

PLANTEO DEL PROBLEMA

Buscamos los **pesos sinápticos**

$$w_{ij}, i = 1, \dots, N, j = 1, \dots, N$$

tal que la red nos devuelva el patrón ξ^μ más cercano a ζ .

MODELO DE HOPFIELD

Es una red neuronal que cumple las siguientes características:

- Cada neurona i es un **perceptrón simple** con la función de activación **escalón** (1, -1).
- Cada par de neuronas (i, j) se conectan por el peso sináptico w_{ij} .

MODELO DE HOPFIELD

Comenzamos con una configuración $S_i = \zeta_i$, $i = 1, \dots, n$, (patrón de consulta)

Queremos ver si hay un conjunto de pesos w_{ij} que hagan a la red alcanzar el estado $S_i = \xi_i^{\mu 0}$, donde $\xi_i^{\mu 0}$ es un patrón almacenado.

Patrón

$\xi_i^{\mu 0}$, $i = 1, \dots, n$ es el estado del patrón almacenado más parecido a ζ_i , $i = 1, \dots, n$.

MODELO DE HOPFIELD

Sea

$$h_i = \sum_{j=1}^N w_{ij} S_j, i \neq j$$

Donde:

- w_{ij} es el peso entre la neurona i y la neurona j
- S_j es el estado de la neurona j
- N es la cantidad de neuronas

MODELO DE HOPFIELD

La neurona i modifica su estado S_i de acuerdo a la regla:

$$S_i = \begin{cases} 1 & \text{si } h_i > 0 \\ -1 & \text{si } h_i < 0 \end{cases}$$

$$S_i = \text{sign}(h_i), h_i \neq 0$$

Si $h_i = 0$ entonces la neurona i permanece en el estado previo.

ESTADO ESTABLE

La red evoluciona hasta que S_i no se modifique más $\forall i = 1, \dots, n$.

Quiere decir que la red alcanzó un **estado estable**

El estado al que evoluciona se lo denomina atractor

CONVERGENCIA

Tenemos N neuronas en la red y un **único patrón** almacenado ξ

Calculamos los w_{ij}

$$w_{ij} = \frac{1}{N} \xi_i \xi_j \quad i, j = 1, \dots, N$$

$$S_i = \text{sign}\left(\sum_{j=1}^N w_{ij} \xi_j\right) = \text{sign}(\xi_i) = \xi_i \forall i$$

debido a que $\xi_j^2 = 1 \quad \forall j = 1, \dots, N$

Por lo tanto, se produce la convergencia: alcanza el patrón almacenado.

-1	-1
1	1

$$\xi = (-1, -1, 1, 1)$$

$\searrow \quad \searrow$
 $\xi_1 \quad \xi_N$

MÚLTIPLES PATRONES

Sean p patrones almacenados.
Podemos elegir los pesos como:

$$w_{ij} = \frac{1}{N} \sum_{\mu=1}^p \xi_i^{\mu} \xi_j^{\mu}, i \neq j$$

Esta ecuación incrementa los pesos entre dos neuronas i y j cuando ambos están activados o ambos desactivados.

Se toma también $w_{ii} = 0$ y $w_{ji} = w_{ij}$

1	1
-1	-1

$$\xi^1 = (1, 1, -1, -1)$$

-1	-1
1	1

$$\xi^2 = (-1, -1, 1, 1)$$

03.2

ALGORITMO

ALGORITMO

1. **Almacenamiento:** Sean $\xi_1, \xi_2, \dots, \xi_p$, patrones N-dimensionales binarios.
2. **Pesos Sinápticos:**

$$w_{ij} = \begin{cases} \frac{1}{N} \sum_{\mu=1}^p \xi_i^{\mu} \xi_j^{\mu} & si \quad i \neq j \\ 0 & si \quad i = j \end{cases}$$

Donde:

- w_{ij} es el peso sináptico entre la neurona i y la j .
- $\xi_1^{\mu} \in \{-1, 1\}$

ALGORITMO

3. **Inicialización.** Sea ζ un vector de consulta N-dimensional desconocido, presentado a la red.

$$S_i(0) = \zeta_i \quad i = 1, \dots, N$$

- $S_i(0)$ es el estado de la neurona i en el tiempo $t = 0$.
- ζ_i es el i -ésimo elemento del vector de consulta que queremos asociar con alguno de los patrones almacenados.

ALGORITMO

4. Iteración hasta la convergencia

Actualizar los elementos del vector de estado $S(t)$ de acuerdo a la regla:

$$S_i(t + 1) = \text{sign}\left(\sum_{j=1}^N w_{ij} S_j(t)\right) , i \neq j$$

Repetir la iteración hasta que el vector de estados S permanezca estable.

MÚLTIPLES PATRONES

5. Output

Sea S_{fijo} el estado fijo o estable calculado al final del paso 3.

S_{fijo} es el patrón asociado con ζ .

Observar que el vector de pesos permanece fijo y que en cada paso cambian los estados S_i .

03.3

EJEMPLO

EJEMPLO

Cantidad de patrones $p = 2$

$$\xi^1 = (1, 1, -1, -1) , \xi^2 = (-1, -1, 1, 1)$$

EJEMPLO

Cantidad de patrones $p = 2$

$$\xi^1 = (1, 1, -1, -1) , \xi^2 = (-1, -1, 1, 1)$$

Cantidad de neuronas $N = 4$ (porque cada patrón tiene 4 elementos)

¿Cuál es el valor de w_{12} y w_{13} ?
Calcular la matriz de pesos W

EJEMPLO

$$w_{ij} = \frac{1}{N} \sum_{\mu=1}^p \xi_i^{\mu} \xi_j^{\mu}, i \neq j$$

Cantidad de patrones $p = 2$

$$\xi^1 = (1, 1, -1, -1), \xi^2 = (-1, -1, 1, 1)$$

Cantidad de neuronas $N = 4$ (porque cada patrón tiene 4 elementos)

$$w_{12} = \frac{1}{4}(\xi_1^1 \xi_2^1 + \xi_1^2 \xi_2^2) = \frac{1}{4}(1 + 1) = 0.5$$

$$w_{13} = \frac{1}{4}(\xi_1^1 \xi_3^1 + \xi_1^2 \xi_3^2) = \frac{1}{4}(-1 - 1) = -0.5$$

EJEMPLO

Cantidad de patrones $p = 2$

$$\xi^1 = (1, 1, -1, -1) , \xi^2 = (-1, -1, 1, 1)$$

Cantidad de neuronas $N = 4$ (porque cada patrón tiene 4 elementos)

$$W = \begin{pmatrix} 0 & 0.5 & -0.5 & -0.5 \\ 0.5 & 0 & -0.5 & -0.5 \\ -0.5 & -0.5 & 0 & 0.5 \\ -0.5 & -0.5 & 0.5 & 0 \end{pmatrix}$$

EJEMPLO

Para calcular la matriz de pesos W

$K = (\xi^1 \ \xi^2)$ (la matriz que se obtiene de poner los patrones en columna)

Entonces

$$W = \frac{1}{N} K K^t$$

$$S(t + 1) = \text{sign}(W S(t))$$

Recordar que la diagonal debe ser 0

EJEMPLO

Pregunta: ¿Qué patrón se le asigna al vector de consulta $\zeta = (1, -1, -1, -1)$?

$$S_1 = \text{sign}(W \zeta) = \text{sign} \begin{pmatrix} 0 & 0.5 & -0.5 & -0.5 \\ 0.5 & 0 & -0.5 & -0.5 \\ -0.5 & -0.5 & 0 & 0.5 \\ -0.5 & -0.5 & 0.5 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \\ -1 \\ -1 \end{pmatrix}$$

$$= \text{sign} \begin{pmatrix} 0.5 \\ 1.5 \\ -0.5 \\ -0.5 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ -1 \\ -1 \end{pmatrix}$$

Llegó al patrón
almacenado ξ^1

$$\xi^1 = (1, 1, -1, -1) , \xi^2 = (-1, -1, 1, 1)$$

EJEMPLO

$$S_2 = \text{sign}(W S_1) = \text{sign} \begin{pmatrix} 0 & 0.5 & -0.5 & -0.5 \\ 0.5 & 0 & -0.5 & -0.5 \\ -0.5 & -0.5 & 0 & 0.5 \\ -0.5 & -0.5 & 0.5 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ -1 \\ -1 \end{pmatrix}$$

$$\text{sign} \begin{pmatrix} 1 \\ 0.5 \\ -1.5 \\ -1.5 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ -1 \\ -1 \end{pmatrix} \longrightarrow \begin{matrix} \text{Se mantiene} \\ \textbf{estable} \end{matrix}$$

$S1 = \xi^1 = (1, 1, -1, -1)$

03.4

CONVERGENCIA

ESTABILIDAD

$$w_{ij} = \frac{1}{N} \sum_{\mu=1}^p \xi_i^{\mu} \xi_j^{\mu}, i \neq j$$

¿Se llega a un estado de **Estabilidad**?

Sea ξ_i^{ν} el elemento i del patrón de consulta ν .
La condición de estabilidad es:

$$\text{sign}(h_i^{\nu}) = \xi_i^{\nu}$$

$$h_i^{\nu} = \sum_j w_{ij} \xi_j^{\nu} = \frac{1}{N} \sum_j \sum_{\mu} \xi_i^{\mu} \xi_j^{\mu} \xi_j^{\nu}$$

Patrones almacenados

Patrón de consulta

ESTABILIDAD

$$h_i^\nu = \frac{1}{N} \sum_j \sum_\mu \xi_i^\mu \xi_j^\mu \xi_j^\nu$$

$$h_i^\nu = \frac{1}{N} \sum_j \sum_{\mu \neq \nu} \xi_i^\mu \xi_j^\mu \xi_j^\nu + \frac{1}{N} \sum_j \xi_i^\nu \xi_j^\nu \xi_j^\nu$$

$$h_i^\nu = \frac{1}{N} \sum_j \sum_{\mu \neq \nu} \xi_i^\mu \xi_j^\mu \xi_j^\nu + \frac{1}{N} \xi_i^\nu$$

crosstalk = 0

$$\text{sign}(h_i^\nu) = \xi_i^\nu$$

El sistema es estable si:

- el término de crosstalk es cero.
- Es decir, cuando los **patrones son ortogonales**

Esta es una de las limitaciones de esta red.

CONVERGENCIA

Hopfield demostró que su red está asociada a una **función de Energía**, dada por:

$$H(w) = -\frac{1}{2} \sum_{i,j} w_{ij} S_i S_j$$

Y que los mínimos locales de esta función son los patrones almacenados.

FUNCIÓN DE ENERGÍA

Propiedad central de una **Función de Energía**

- Siempre decrece (o permanece constante) cuando el sistema evoluciona.
- Como los pesos sinápticos son simétricos:

$$H(w) = - \sum_{j>i} w_{ij} S_i S_j$$

Porque $w_{ij} = w_{ji}$, entonces puedo sumar solo la parte superior de la matriz y multiplicar por 2 (parte superior e inferior de la matriz W). Además $w_{ii} = 0$

FUNCIÓN DE ENERGÍA


$$H(w) = - \sum_{j>i} w_{ij} S_i S_j$$

Sea S_i' el nuevo valor de S_i $S_i' = \text{sign} \sum_{j \neq i} w_{ij} S_j$

Si $S_i' = S_i$ la energía no se modifica

Si $S_i' = -S_i$ entonces (cambió de signo):

$$\Delta H = H' - H = - \sum_{j>i} w_{ij} S_i' S_j + \sum_{j>i} w_{ij} S_i S_j$$

$$2S_i \sum_{j>i} w_{ij} S_j < 0$$


Estamos considerando los S_i' con signo contrario a S_i entonces la energía decrece cada vez que un S_i cambia.

LIMITACIONES

- El número máximo de patrones que puede almacenar es igual al 15 % del número de neuronas de la red. Es decir,

$$p \leq 0,15 * N$$

donde N es la dimensión de los patrones

- Los patrones deben ser “más o menos” ortogonales.

ESTADOS ESPURIOS

- Los patrones son atractores.
- La Función de Energía H puede tener otros mínimos locales que no son los patrones almacenados.



Estados Espurios

También son atractores
Puede desembocar en ciclos

BIBLIOGRAFÍA

[1] McKay D.J.C. *Hopfield Networks*. Information Theory, Inference and Learning Algorithms, Cambridge, 2003.

[2] Anders Krogh John Hertz and Richard Palmer. *Introduction to the Theory of Neural Computation*. Addison-Wesley, 1991.